Universidad Rafael Landívar
Facultad de Ingeniería
Ingeniería en Informática y de Sistemas
Ciencia de Datos
Sección No. 2
Ing. Max Cerna

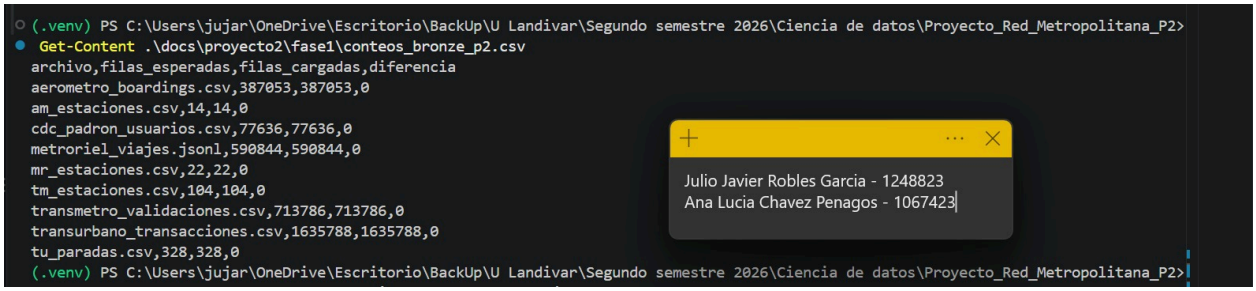
Proyecto 2

Ana Lucia Chavez Penagos - 1067423
Julio Javier Robles García - 1248823

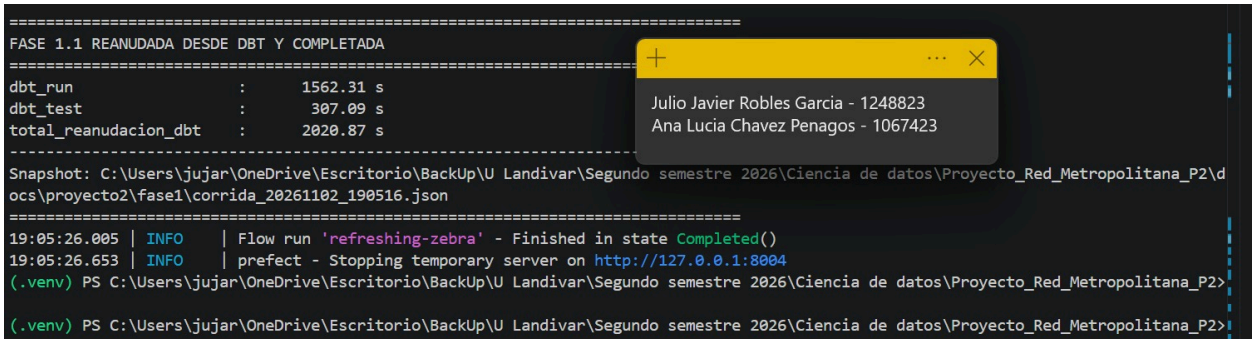
Guatemala, 02 de noviembre de 2026

Evidencias

Evidencia 1. Validación de conteos de los nueve archivos en la capa Bronze



Evidencia 2. Finalización satisfactoria del flujo automatizado de la Fase 1.1

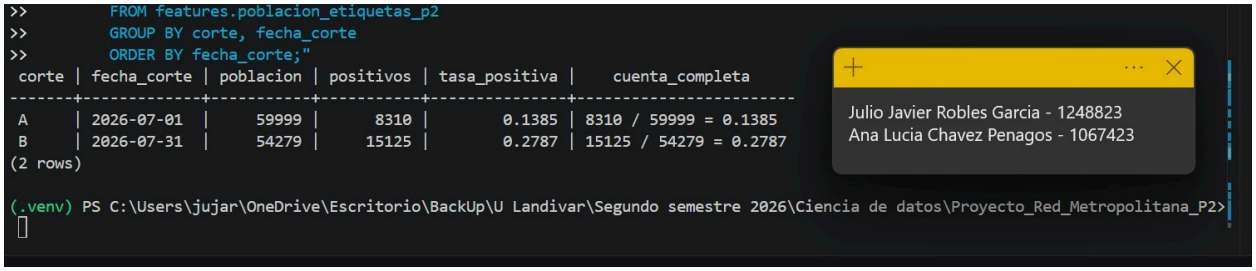


Decisión para tratar un usuario

Para el Proyecto 2 decidimos mantener como unidad de análisis al usuario unificado construido en el Proyecto 1. Esta decisión permite analizar el abandono a nivel de persona y no solamente a nivel de tarjeta, ya que un mismo usuario puede tener actividad en distintos sistemas de transporte. De esta forma, consideramos que un usuario abandona la red únicamente cuando deja de presentar actividad válida en todos los operadores durante el período definido para la etiqueta.

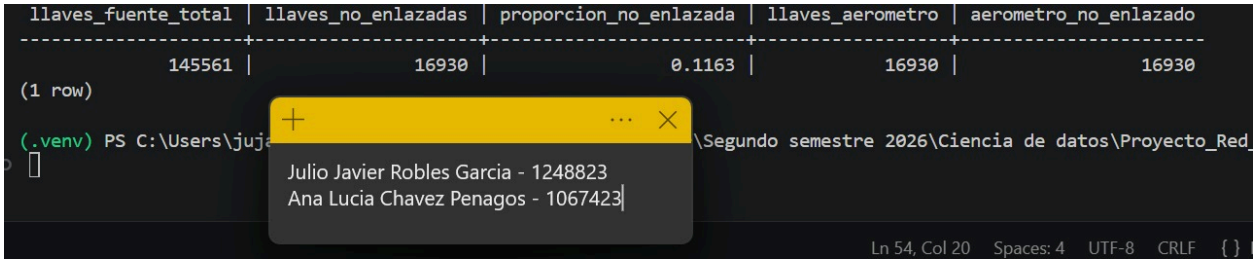
La limitación también queda desde ya definida:
La integración de identidad no es perfecta. Aerómetro mantiene usuarios aislados porque no existe un mecanismo confiable para relacionar su user_hash con las identidades de los demás operadores. Además, cuando no existe una relación entre tarjetas de distintos sistemas, estas pueden representar unidades separadas aunque pertenezcan a una misma persona. Esta limitación puede aumentar artificialmente la cantidad de usuarios y afectar la medición del abandono, por lo que será cuantificada en los resultados.

Evidencia 3. Población, positivos y tasa de abandono para los cortes A y B



Se calcularon la población y la etiqueta para los cortes A y B utilizando únicamente registros válidos de Silver. En A se obtuvieron 8,310 positivos de 59,999 personas (13.85%), mientras que en B se obtuvieron 15,125 positivos de 54,279 personas (27.87%).

Evidencia 4 — Costo de utilizar persona como unidad



De las 145,561 llaves fuente disponibles, 16,930 no pudieron relacionarse con identidades de otros operadores, equivalente al 11.63%. Todas corresponden a Aerómetro y se conservaron como identidades aisladas por no existir un crosswalk confiable.

Unidad elegida:

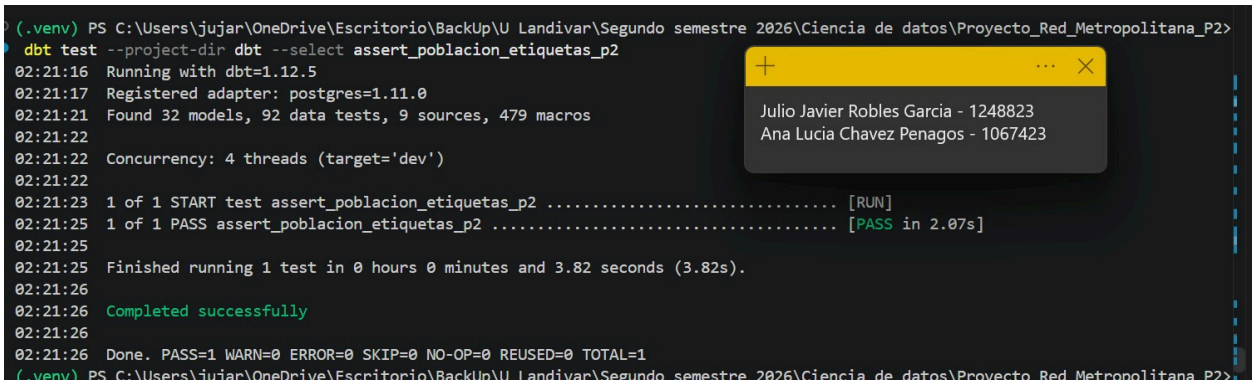
Utilizamos la persona como unidad de análisis, representada mediante usuario_id. Esta decisión mantiene la estrategia de identidad construida en el Proyecto 1, donde las llaves provenientes de distintos operadores se relacionan cuando existe información suficiente para hacerlo. Esto permite evitar que una persona que cambia de tarjeta u operador sea considerada automáticamente como un abandono. En los casos donde no existe una relación confiable, la identidad se mantiene separada en lugar de asumir una correspondencia que no podemos demostrar.

Definición de la etiqueta:

La etiqueta vale 1 cuando una persona de la población no registra ningún abordaje válido en ningún operador durante los 30 días que comienzan en la fecha de corte, y vale 0 cuando registra al menos uno.

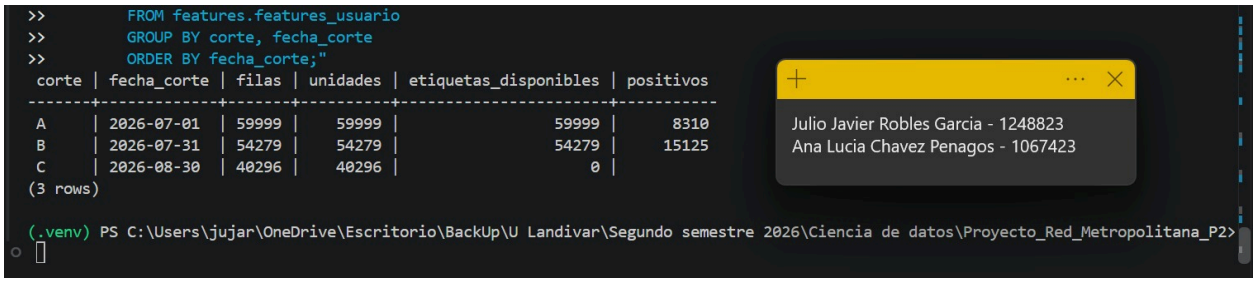
Para Aerómetro:
Aerómetro se mantiene como una identidad aislada porque su user_hash no tiene un crosswalk confiable con las tarjetas de los demás operadores; por esta razón no intentamos unirlo artificialmente y medimos cuántas llaves permanecen sin enlace como costo de trabajar a nivel de persona.

Evidencia 5 — Validación de población y etiqueta mediante dbt

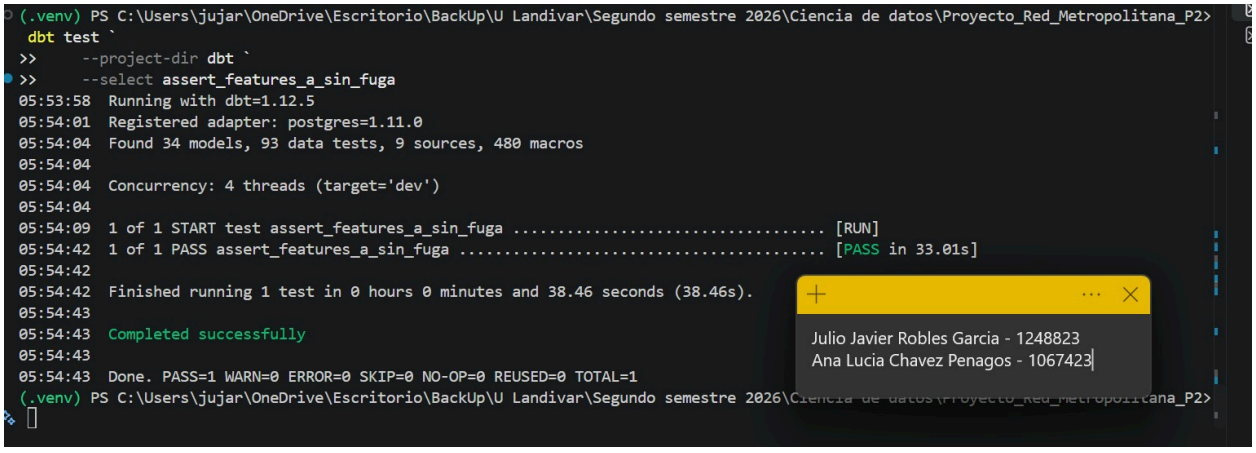


La prueba de calidad confirmó que no existen duplicados por unidad y corte, que todas las personas cumplen las condiciones de población y que las etiquetas contienen únicamente valores válidos.

Evidencia 6. Tabla de features para los cortes A, B y C

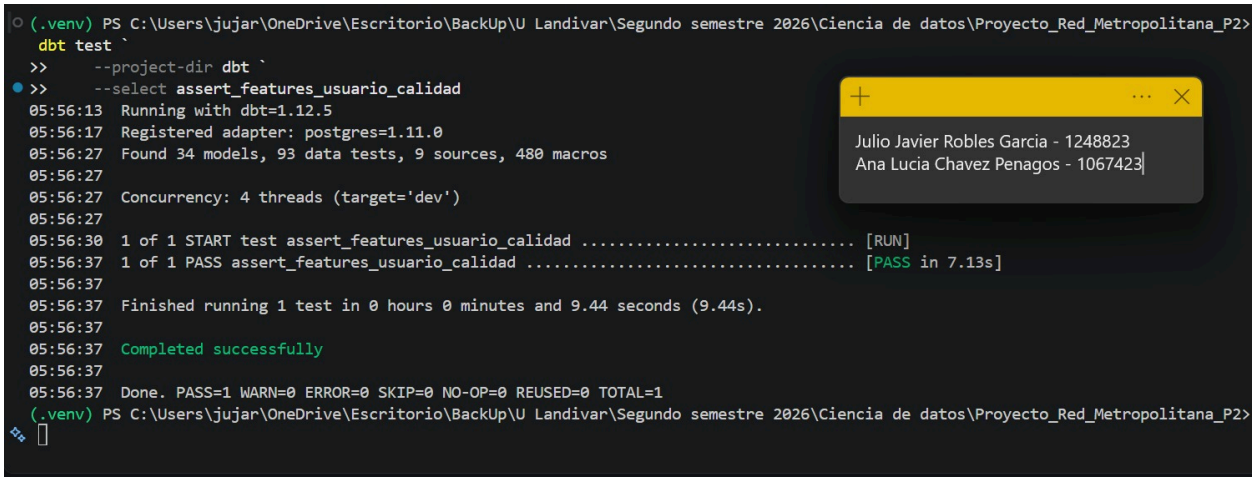


Evidencia 7. Validación de ausencia de fuga de datos en el corte A

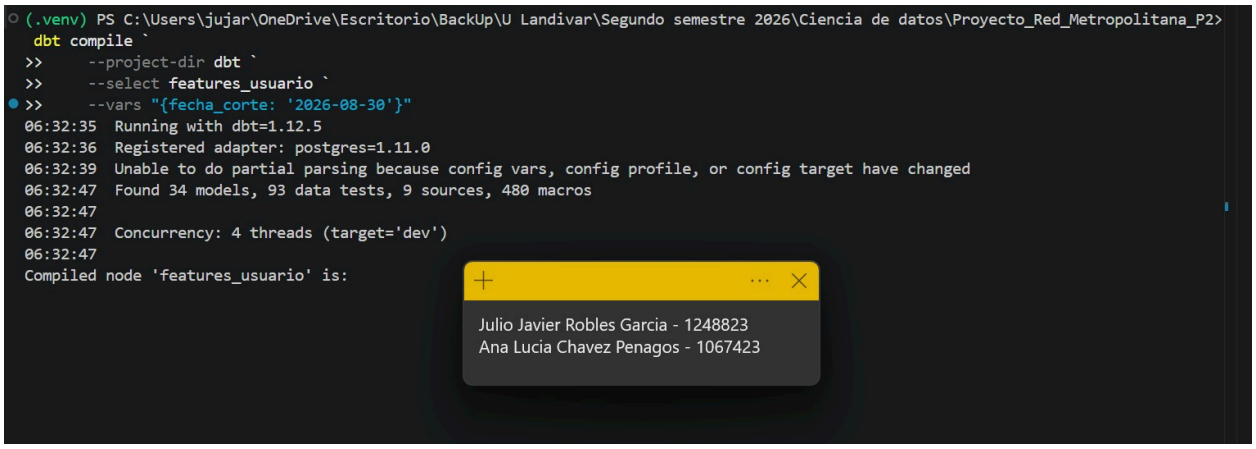


Se recalcularon las features del corte A utilizando los datos completos y posteriormente utilizando únicamente información disponible hasta el 30 de junio de 2026. Ambas tablas contienen 59,999 unidades y se obtuvieron 0 diferencias, por lo que no se encontró evidencia de fuga de información futura.

Evidencia 8. Validación de calidad de la tabla de features

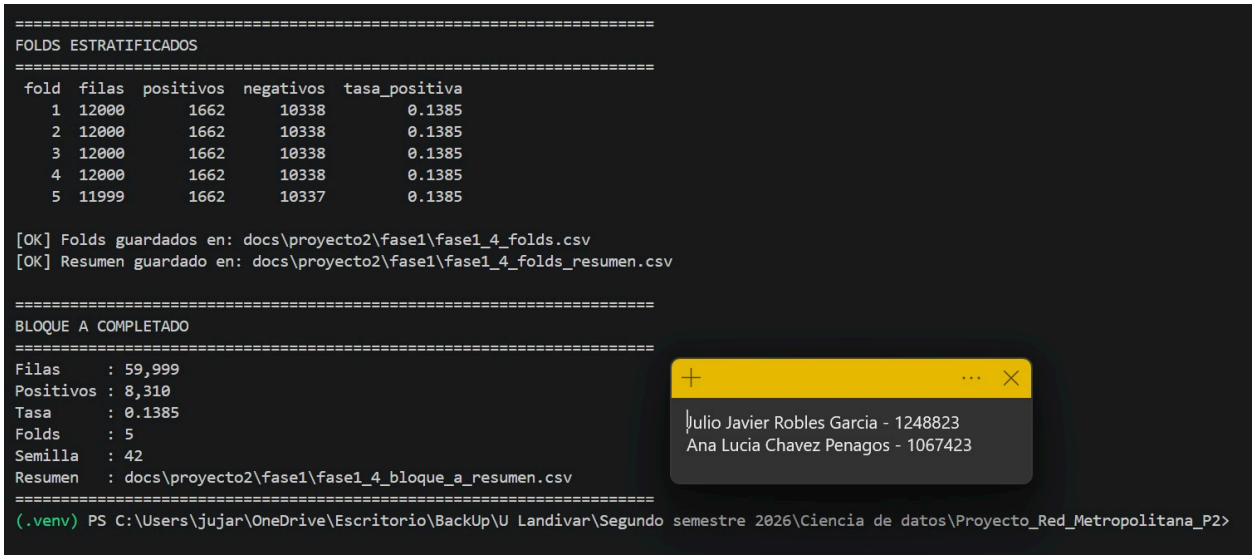


Evidencia 9. Parametrización de la fecha de corte en la tabla de features



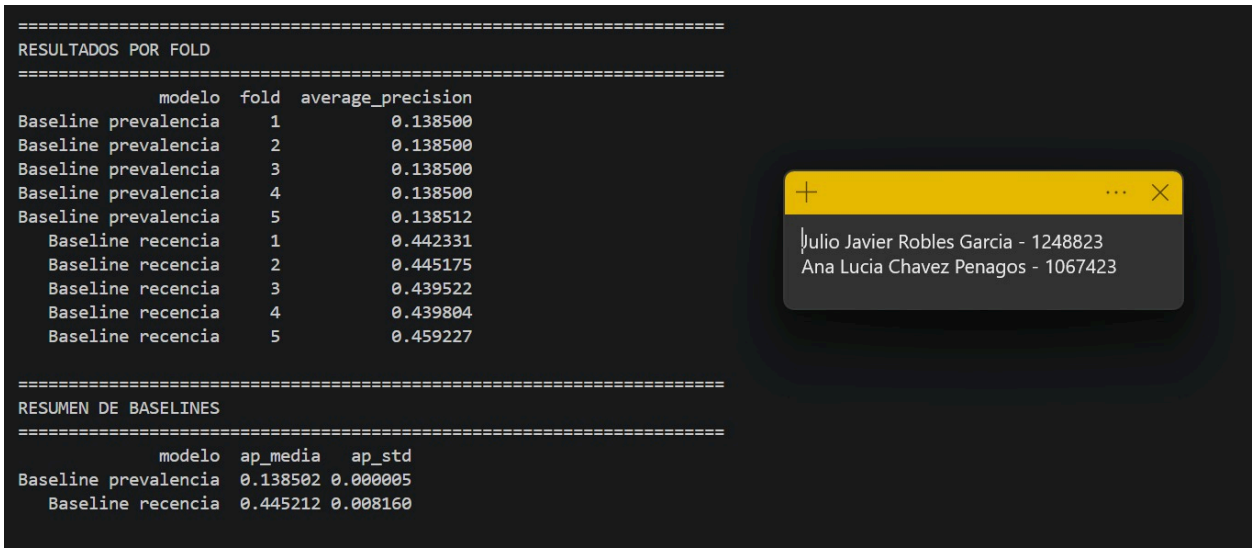
Se verificó que la tabla de features recibe la fecha de corte como parámetro. La misma lógica puede ejecutarse para los cortes A, B y C sin modificar el código del modelo.

Evidencia 10. Preparación del corte A y generación de los cinco folds estratificados



Se utilizó únicamente el corte A para preparar los datos de entrenamiento. La población contiene 59,999 personas, de las cuales 8,310 corresponden a abandono, equivalente al 13.85%. Se generaron cinco folds estratificados con semilla fija 42 para mantener una proporción similar de positivos en cada partición y reutilizar exactamente las mismas divisiones en todos los modelos.

Evidencia 11. Comparación de los dos modelos baseline mediante validación cruzada



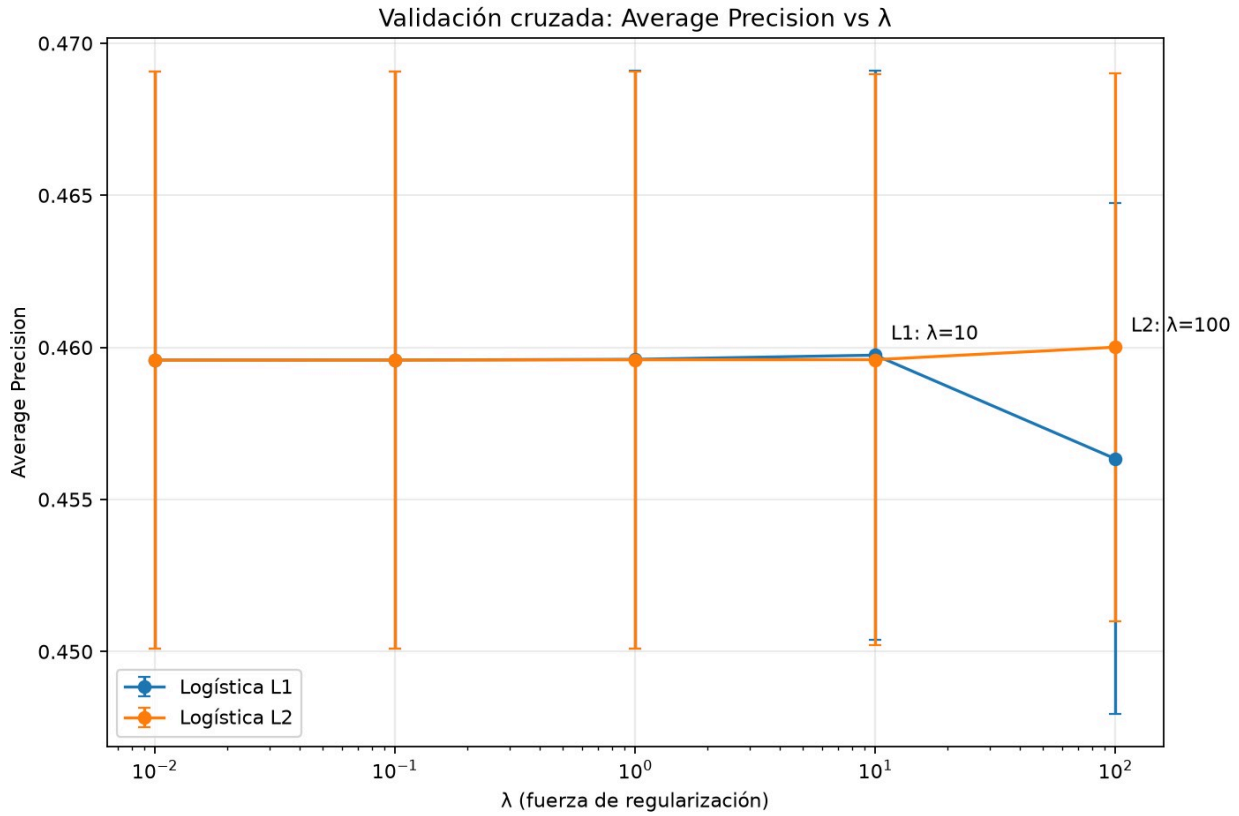
Se evaluaron dos líneas base utilizando exactamente los mismos cinco folds estratificados del corte A. El primer baseline asigna a todos los usuarios la tasa positiva observada en A, mientras que el segundo utiliza únicamente los días desde el último viaje como puntaje de riesgo. Ambos fueron comparados mediante Average Precision.

Evidencia 12. Comparación de baselines y regresiones logísticas mediante validación cruzada

```
======================================================================
COMPARACIÓN FINAL DE MODELOS
======================================================================
                modelo                configuracion  ap_media    ap_std
          Logística L2           lambda=100; C=0.01  0.460007 0.009004
          Logística L1             lambda=10; C=0.1  0.459745 0.009365
   Baseline recencia dias_desde_ultimo_viaje  0.445212 0.008160
Baseline prevalencia             p = 8310 / 59999  0.138502 0.000005
```

Julio Javier Robles Garcia - 1248823
Ana Lucia Chavez Penagos - 1067423

Evidencia 13. Selección de λ mediante validación cruzada para L1 y L2



La gráfica muestra que el desempeño de ambas regularizaciones se mantiene bastante estable para los diferentes valores de λ. En L1, una regularización demasiado fuerte (λ = 100) reduce el desempeño, mientras que L2 presenta una pequeña mejora y alcanza su mayor Average Precision con λ = 100. Se seleccionó L2 con λ = 100 como mejor configuración, con AP media de 0.460007 ± 0.009004. La diferencia respecto a L1 es pequeña, por lo que ambos modelos presentan un comportamiento similar.

Evidencia 14. Coeficientes que más empujan hacia el abandono

```
================================================================================
TOP 5 COEFICIENTES POSITIVOS
================================================================================
                   feature  coeficiente
   dias_desde_ultimo_viaje     0.732171
zona_mas_frecuente_Zona 13     0.234181
zona_mas_frecuente_Zona 10     0.151281
                viajes_14d     0.127328
                viajes_28d     0.101157
```

El coeficiente positivo más alto corresponde a dias_desde_ultimo_viaje, confirmando que la falta de actividad reciente es una de las señales más importantes de riesgo. También aparecen Zona 13, Zona 10 y variables de frecuencia. Estas últimas se interpretan considerando que el modelo incluye simultáneamente varias medidas relacionadas de actividad, por lo que sus coeficientes representan efectos condicionados por las demás variables.

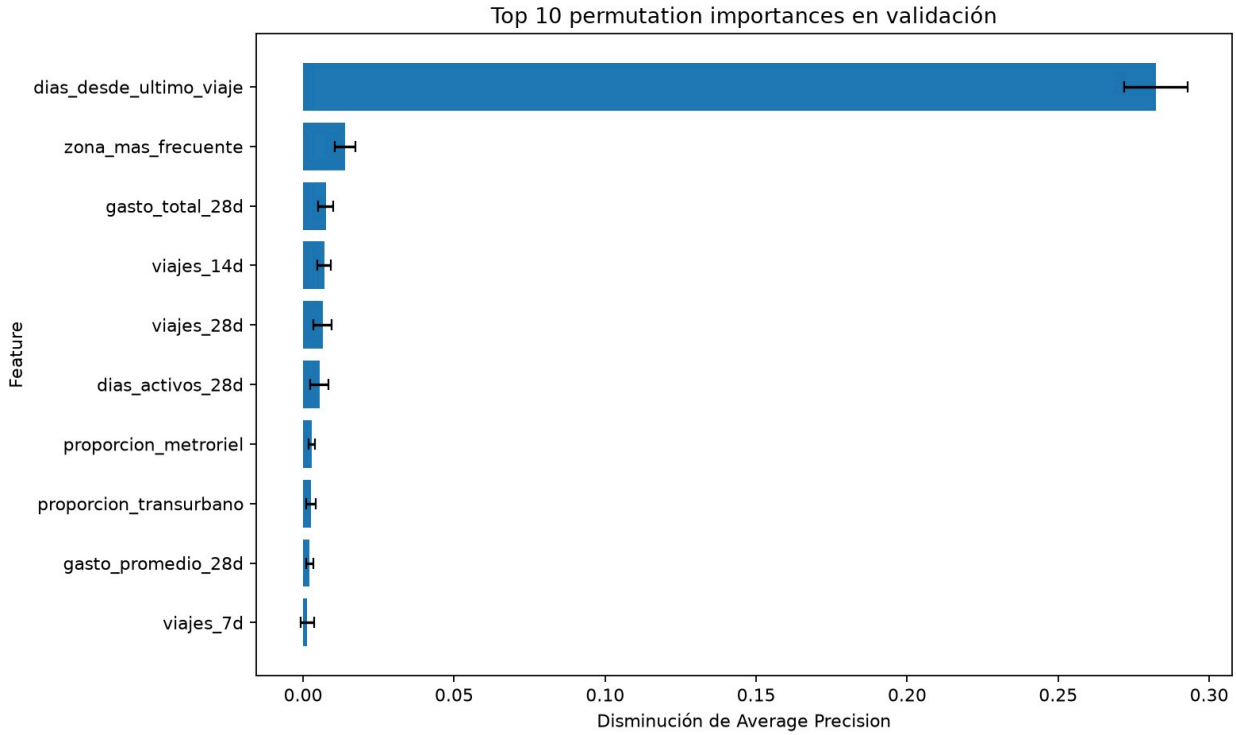
Evidencia 15. Rendimiento de entrenamiento y validación del modelo ensemble

```
======================================================================
RESUMEN ENSEMBLE
======================================================================
             modelo  ap_train_media  ap_train_std  ap_validacion_media  ap_validacion_std  brecha_media  tiempo_entrenam
iento_medio_s
HistGradientBoosting        0.507178      0.002215             0.478147           0.008159      0.029031
       2.3257

Tiempo total CV: 20.34 s
```

El modelo HistGradientBoosting fue evaluado utilizando exactamente los mismos cinco folds estratificados definidos en la Fase 1. Se obtuvo un Average Precision medio de 0.507178 en entrenamiento y 0.478147 en validación, con una brecha promedio de 0.029031. El resultado supera la AP de validación de la regresión logística L2 (0.460007), aunque la diferencia entre entrenamiento y validación muestra que el ensemble presenta cierta tendencia a mayor varianza.

Evidencia 16. Top 10 variables más importantes del ensemble mediante permutation importance en validación



La importancia por permutación se calculó únicamente sobre los conjuntos de validación de los cinco folds. dias_desde_ultimo_viaje fue por amplio margen la variable más importante, lo cual confirma que la recencia es una señal clave del abandono. También aportaron información la zona más frecuente, el gasto total, la frecuencia de viajes y los días activos. Las barras representan la variación de la importancia entre los folds.

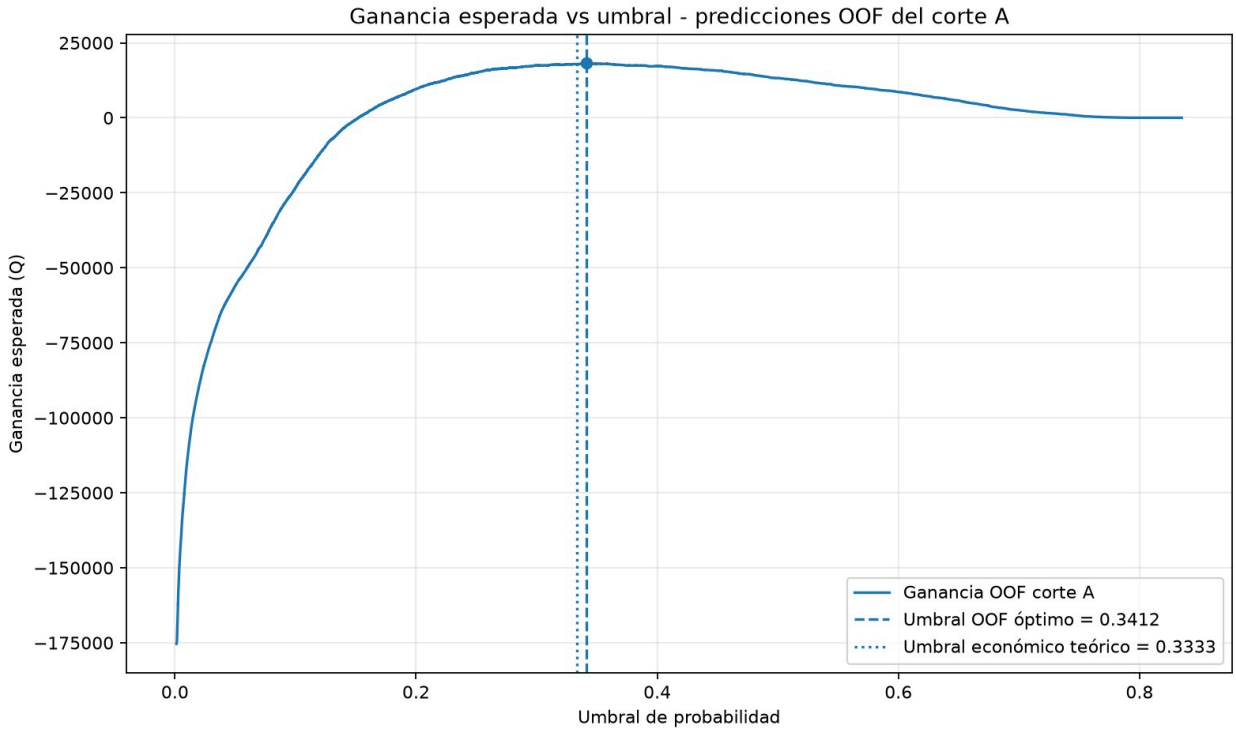
Evidencia 17. Comparación final y selección del modelo ensemble

```
======================================================================
COMPARACIÓN FINAL
======================================================================
              modelo  ap_train_media  ap_train_std  ap_validacion_media  ap_validacion_std  brecha_media
HistGradientBoosting        0.507178      0.002215             0.478147           0.008159      0.029031
        Logística L2        0.460862      0.002364             0.460007           0.009004      0.000855
        Logística L1        0.460699      0.002250             0.459745           0.009365      0.000954
   Baseline recencia        0.444777      0.002006             0.445212           0.008160     -0.000435
Baseline prevalencia        0.138502      0.000001             0.138502           0.000005     -0.000000

======================================================================
```

HistGradientBoosting obtuvo el mayor Average Precision de validación con 0.478147 ± 0.008159, superando a la regresión logística L2, que obtuvo 0.460007 ± 0.009004. El ensemble presenta una mayor brecha entre entrenamiento y validación (0.029031), lo que indica mayor varianza, pero la mejora también se mantiene en validación. Por esta razón se seleccionó HistGradientBoosting como modelo candidato para producción.

Evidencia 18. Selección del umbral mediante ganancia esperada sobre predicciones OOF del corte A



A partir del escenario económico se obtuvo un umbral teórico de 0.3333. Posteriormente evaluamos la ganancia utilizando únicamente las predicciones OOF del corte A y encontramos una ganancia máxima de Q18,165 con un umbral de 0.341156. Este umbral contacta a 7,227 personas, con precision de 0.5009 y recall de 0.4356. Se seleccionó este valor antes de utilizar la etiqueta del corte B.

Evidencia 19. Congelamiento del modelo y umbral antes de la evaluación del corte B

```
================================================================================

MODELO CONGELADO
--------------------------------------------------------------------------------
Modelo       : HistGradientBoostingClassifier
Versión      : p2_hgb_v1
AP CV        : 0.478147 ± 0.008159
Umbral       : 0.341156
Ganancia OOF : Q18,165.00

ARCHIVOS
--------------------------------------------------------------------------------
[OK] modeling\fase2_2_config_modelo_congelado.json
[OK] docs\proyecto2\fase2\fase2_2_pretest_b.md

================================================================================
ESTADO: B NO EVALUADO
================================================================================
[OK] Modelo congelado.
[OK] Hiperparámetros congelados.
[OK] Features congeladas.
[OK] Umbral congelado.
[OK] Listo para crear el commit pre-test.
```

Antes de utilizar la etiqueta del corte B se congelaron el modelo HistGradientBoosting, sus hiperparámetros, las features y el umbral OOF de 0.341156. El estado fue guardado en Git para dejar evidencia reproducible de que cualquier resultado posterior de B no se utilizó para reajustar el modelo.

Evidencia 20. Única evaluación del modelo final sobre el corte B

```
================================================================================
RESULTADO ÚNICO DEL TEST B
================================================================================
Fecha                : 2026-11-11T22:45:37.393109-06:00
Pre-test commit      : e8ae9366345c61fccb82e65519533bf00fe450c8
Commit evaluación    : ae48cb2647e8fc06012ee33856b3b5ce6d59a1fe

Población B          : 54,279
Positivos B          : 15,125
Tasa positiva B      : 0.2787

AP CV corte A        : 0.478147
AP test B            : 0.651994
Diferencia B - CV    : 0.173847

Umbral congelado     : 0.341156
Contactados          : 16,739
Precision            : 0.6399
Recall               : 0.7082

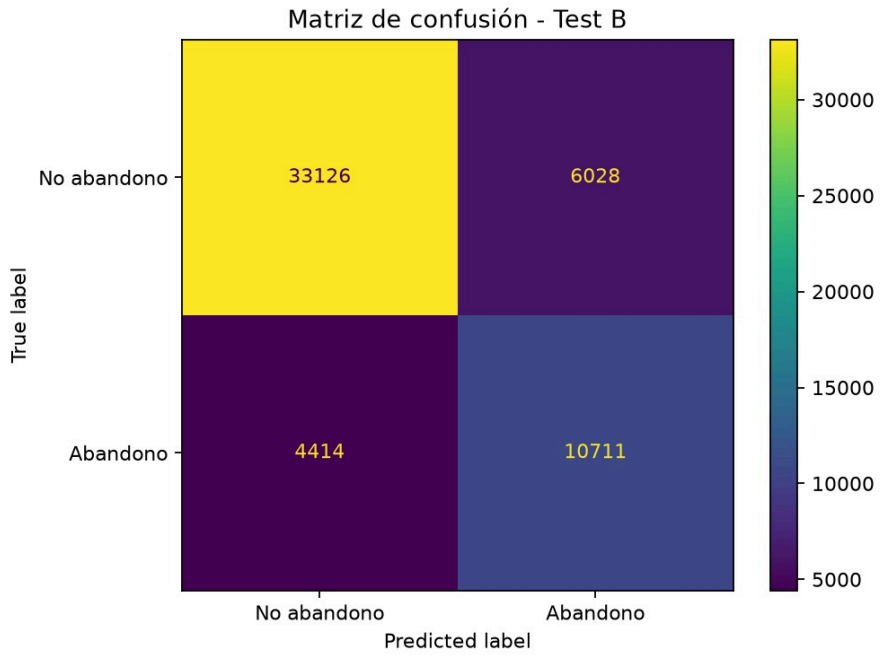
MATRIZ DE CONFUSIÓN
--------------------------------------------------------------------------------
TN: 33,126    FP: 6,028
FN: 4,414    TP: 10,711

RESULTADO ECONÓMICO
--------------------------------------------------------------------------------
Retenidos esperados   : 2,677.75
Costo total           : Q83,695.00
Beneficio esperado    : Q160,665.00
GANANCIA B            : Q76,970.00

Tiempo entrenamiento  : 13.95 s
Tiempo predicción     : 0.80 s
```

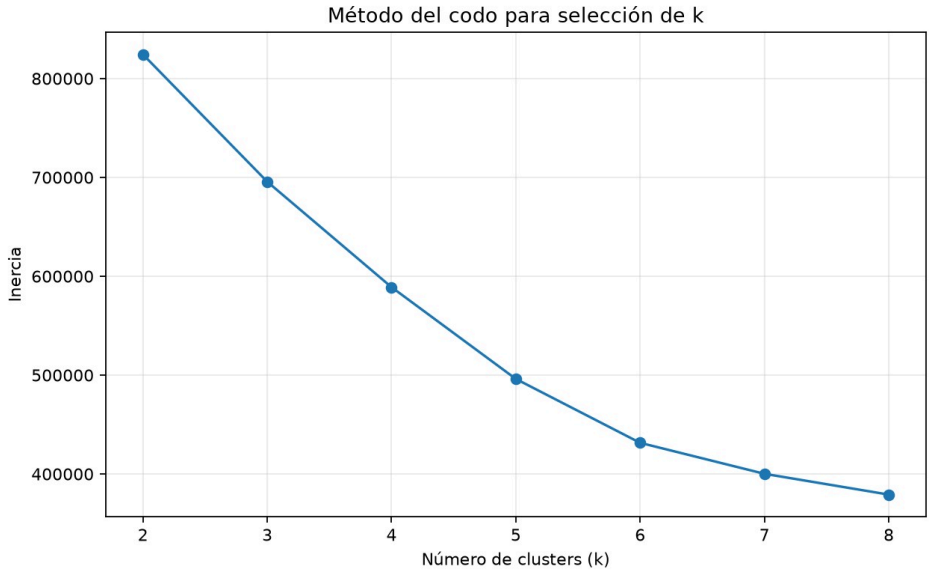
El modelo HistGradientBoosting se entrenó finalmente con todo el corte A y se evaluó una sola vez sobre el corte B utilizando el umbral previamente congelado de 0.341156. Se obtuvo un Average Precision de 0.651994, precision de 0.6399 y recall de 0.7082. La campaña contactaría a 16,739 personas y produciría una ganancia esperada de Q76,970 bajo el escenario económico definido.

Evidencia 21. Matriz de confusión de la única evaluación sobre el corte B



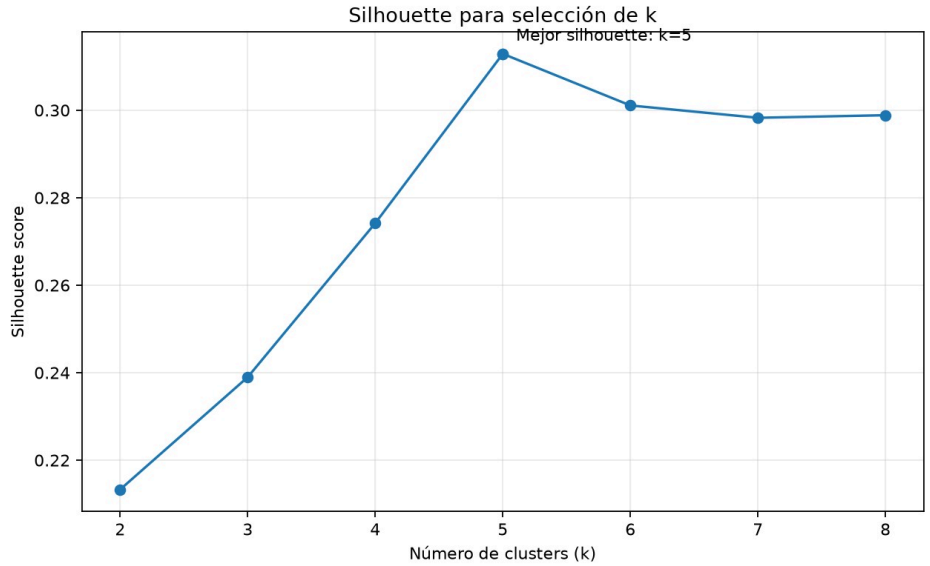
Con el umbral congelado, el modelo identificó correctamente 10,711 personas que abandonarían la red y 33,126 que continuarían utilizándola. También produjo 6,028 falsos positivos y 4,414 falsos negativos. El resultado muestra un balance favorable entre precision y recall para la decisión de contacto.

Evidencia 22. Selección del número de segmentos mediante el método del codo



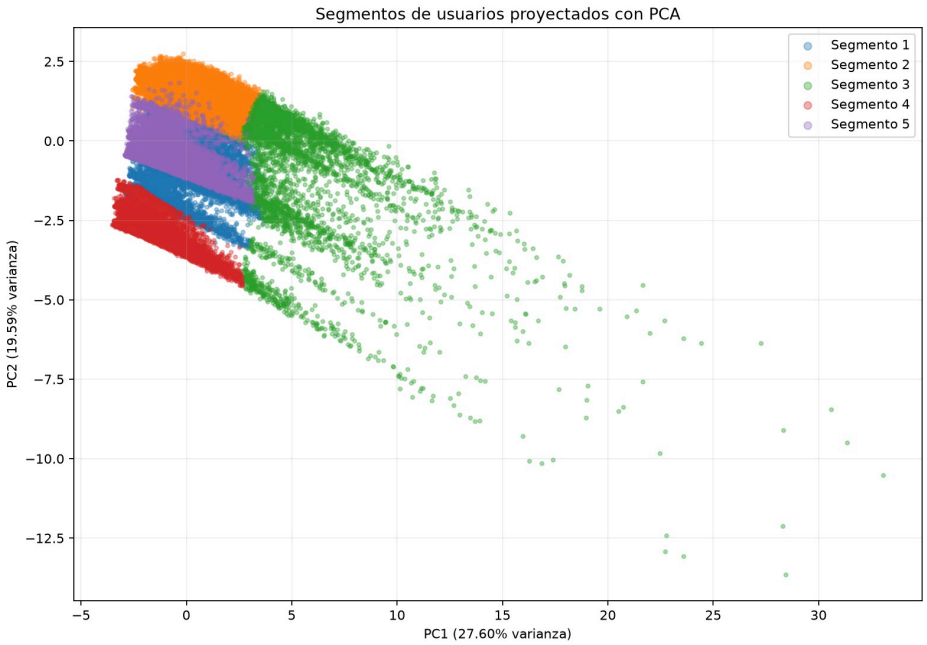
La inercia disminuye de forma importante al aumentar el número de clusters, pero a partir de aproximadamente k=5 la reducción comienza a ser menor. Este comportamiento indica que cinco segmentos ofrecen un buen equilibrio entre compactación de los grupos y complejidad del modelo.

Evidencia 23. Evaluación del número de segmentos mediante silhouette



El mayor silhouette score se obtuvo con k=5, indicando que esta configuración genera la mejor combinación entre cohesión interna y separación entre segmentos dentro de los valores evaluados. Al considerar este resultado junto con el método del codo, seleccionamos cinco segmentos para el análisis final.

Evidencia 24. Visualización de los cinco segmentos mediante PCA



Los cinco segmentos obtenidos con KMeans fueron proyectados sobre dos componentes principales para facilitar su visualización. PC1 explica 27.60% de la varianza y PC2 19.59%, para una varianza acumulada de 47.19%. La proyección permite observar diferencias entre los grupos, aunque existe cierto solapamiento porque PCA muestra únicamente dos dimensiones de las 34 utilizadas originalmente para formar los segmentos.

Evidencia 25. Caracterización final de los cinco segmentos de usuarios

```
================================================================================
TABLA FINAL DE SEGMENTOS
================================================================================
 segmento                          nombre  tamanio  tasa_abandono  mediana_viajes_28d  mediana_dias_activos_28d  mediana_dias_desde_ultimo_viaje modo_mas_usado
o_moda prioridad_retencion
       1   Usuarios principalmente MetroRiel     9968       0.139547                 9.0                       7.0                          2.64845          MET
RORIEL              Media
       2 Usuarios principalmente Transurbano    27207       0.152718                10.0                       7.0                          2.34350        TRANS
URBANO               Alta
       3   Usuarios intensivos y muy activos     4152       0.014933                61.0                      22.0                          0.42745        TRANS
URBANO               Baja
       4   Usuarios ocasionales de Aerómetro    10111       0.144298                 6.0                       5.0                          3.70710          AER
OMETRO         Media-Alta
       5  Usuarios principalmente Transmetro     8561       0.145193                 9.0                       7.0                          2.35370         TRAN
SMETRO              Media
```

Los segmentos fueron caracterizados utilizando las medianas de sus principales features. El segmento 2, denominado “Usuarios principalmente Transurbano”, concentra la mayor población y presenta la mayor tasa de abandono con 15.27%. En contraste, el segmento 3, “Usuarios intensivos y muy activos”, registra 61 viajes medianos en 28 días, 22 días activos y una tasa de abandono de solo 1.49%. Las tasas se utilizan de manera descriptiva y no implican causalidad.

Evidencia 26. Guardado y validación del modelo final de producción

```
================================================================================
MODELO FINAL GUARDADO
================================================================================
Archivo       : models/modelo_churn_p2_hgb_v1.joblib
Versión       : p2_hgb_v1
Entrenado con : corte A (59,999 filas)
Umbral        : 0.341156
AP CV A       : 0.478147
SHA256        : 08e6f4b8e4c8df5172943d34250049ae211eaeb53cfb9bad0a807675c43b9a9d
```

Se entrenó el pipeline final HistGradientBoosting únicamente con las 59,999 unidades del corte A y se guardó como modelo_churn_p2_hgb_v1.joblib. El archivo incluye el preprocesamiento y el clasificador, utiliza el umbral congelado de 0.341156 y puede cargarse desde disco sin reentrenar. La comparación de predicciones antes y después de guardar el modelo produjo una diferencia máxima de cero.

Evidencia 27. Generación reproducible de las predicciones del corte C

```
================================================================================
PREDICCIONES GENERADAS
================================================================================
Modelo        : modelo_churn_p2_hgb_v1.joblib
Umbral        : 0.341156328362
Filas         : 40,296
Contactar=1   : 5,480
Contactar=0   : 34,816
Score mínimo  : 0.001621
Score máximo  : 0.793317

CSV           : predicciones\predicciones_corte_C.csv
SHA256 CSV    : e7397c3d8e2a02f7f12640e1e497af3ba28b6f03f0102a1fc5db03d1b801e028
Manifest      : predicciones\predicciones_corte_C.manifest.json

[OK] El modelo fue cargado desde disco.
[OK] predecir.py NO reentrenó el modelo.
[OK] Se respetó la fecha de corte solicitada.
```

El script predecir.py generó las predicciones para el corte C del 30 de agosto de 2026 utilizando el modelo previamente guardado, sin reentrenarlo. La población de producción contiene 40,296 unidades, de las cuales 5,480 superan el umbral congelado de 0.341156 y serían contactadas. El CSV quedó registrado junto con su hash SHA256 para poder comprobar posteriormente su invariancia.

Evidencia 28. Validación del archivo de predicciones del corte C

```
(.venv) PS C:\Users\jujar\OneDrive\Escritorio\BackUp\U Landivar\Segundo semestre 2026\Ciencia de datos\Proyecto_Red_Metropo
litana_P2> python -c "import pandas as pd; d=pd.read_csv('predicciones/predicciones_corte_C.csv'); print('Columnas:', d.col
umns.tolist()); print('Filas:', len(d)); print('Duplicados:', d['unidad_id'].duplicated().sum()); print('Nulos:', d.isna().
sum().sum()); print('Contactar:', d['contactar'].value_counts().sort_index().to_dict()); print('Scores fuera [0,1]:', ((d['
puntaje']<0)|(d['puntaje']>1)).sum()); print('Tarjetas vacias:', d['tarjetas'].isna().sum())"
Columnas: ['unidad_id', 'tarjetas', 'puntaje', 'contactar']
Filas: 40296
Duplicados: 0
Nulos: 0
Contactar: {0: 34816, 1: 5480}
Scores fuera [0,1]: 0
Tarjetas vacias: 0
(.venv) PS C:\Users\jujar\OneDrive\Escritorio\BackUp\U Landivar\Segundo semestre 2026\Ciencia de datos\Proyecto_Red_Metropo
litana_P2>
```

El archivo final contiene una fila por unidad de la población C y las cuatro columnas requeridas: unidad_id, tarjetas, puntaje y contactar. Se validaron 40,296 filas sin duplicados, valores nulos ni puntajes fuera del intervalo [0,1]. De estas unidades, 5,480 fueron clasificadas para contacto.

Evidencia 29. Verificación local de invariancia de las predicciones del corte C

```
======================================================================
PRUEBA DE INVARIANCIA - CORTE C
======================================================================

Filas baseline      : 40,296
Filas actual        : 40,296

Mismas filas        : True
Mismas unidades     : True
Mismas tarjetas     : True
Mismos contactos    : True

Diferencia máxima score: 0.000000000000

SHA baseline: e7397c3d8e2a02f7f12640e1e497af3ba28b6f03f0102a1fc5db03d1b801e028
SHA actual  : e7397c3d8e2a02f7f12640e1e497af3ba28b6f03f0102a1fc5db03d1b801e028

======================================================================
RESULTADO: INVARIANCIA SUPERADA
[OK] Las predicciones del corte C son exactamente idénticas.
----------------------------------------------------------------------
```

Se comparó el archivo original de predicciones del corte C con una copia baseline. Las 40,296 filas conservaron exactamente las mismas unidades, tarjetas, decisiones de contacto y puntajes. La diferencia máxima entre puntajes fue 0.000000000000 y ambos archivos obtuvieron el mismo SHA256: e7397c3d8e2a02f7f12640e1e497af3ba28b6f03f0102a1fc5db03d1b801e028. Esta prueba valida nuestro mecanismo de comparación; la prueba definitiva de invariancia se realizará durante la evaluación con los 30 días adicionales de datos suministrados por el catedrático.